




ІТМО

**Разработка MVP прикладного программного
продукта**


**«Интеллектуальная система
предиктивной аналитики
успеваемости студентов»**

Состав команды

ИТМО



СЕРГЕЙ ПОКРОВСКИЙ
Product Owner/Team Lead



АННА ВОЗИАНОВА
ML Team Lead



МАРИЯ МОСКАЛЕНКО
Data Analyst/Scientist



ИЛЬЯ САВЕНОК
ML Engineering Support



АРТЁМ ПШЕНИЧНИКОВ
IT Engineering Support



МАРГАРИТА КУДРИНСКАЯ
Software Tester



ВЛАДИСЛАВ ТЕРЕЩЕНКО
Project Supervisor



ТРЕНДЫ

1. Разработка и применение интеллектуальных программ и систем для образования
2. Превентивные меры по реагированию на риски снижения успеваемости



ПРОБЛЕМАТИКА

1. Нехватка готовых российских инструментов предиктивной аналитики успеваемости
2. Позднее обнаружение и реагирование на снижение успеваемости
3. Недостаток предиктивной учебной аналитики

Разработать MVP прикладного программного продукта для предсказания успеваемости с акцентом на группы риска

1. Сбор сырых данных из ИСУ
2. Подготовка и очистка данных
3. Машинное обучение моделей
4. Сравнение и выбор модели по метрикам качества
5. Предсказание результатов успеваемости
6. Построение графической аналитики и ее интерпретация
7. Разработка MVP программного продукта
8. Проведение испытаний и разработка документации

ДВЕ ОСНОВНЫЕ ЗАДАЧИ:

1. Многоклассовая

(прогноз итоговой оценки по шкале от 2 до 5)

2. Бинарная

(прогноз успешности освоения дисциплины)

ДЛЯ АНАЛИЗА ИСПОЛЬЗОВАЛИСЬ:

1. Реальные данные, включающие: количественные показатели (например, средние оценки, количество предметов)
2. Категориальные признаки (например, дисциплины, семестры и др.)
3. Отдельное внимание уделялось обработке пропущенных значений и их влиянию на качество моделей.



Входные данные и витрины признаков (ML-пайплайн)

ИТМО

Задача: прогноз результата по дисциплине по данным студента

Записей (сырьё)

230 958

Студентов

6 570

Период

2021/2022 – 2025/2026

Дисциплин

846

4 витрины признаков пайплайна

Сырые входные данные

- 14 столбцов: 13 входных + 1 целевая (ОЦЕНКА)
- Одна строка = студент × дисциплина × вид контроля × попытка
- Пропуски: АДРЕС — 18.1%;
УСЛОВИЕ_ЗАЧИСЛЕНИЯ — 10.4%
- Полные дубликаты строк — 0.98%
- Таргет смешанный: числовые оценки (2–5) и бинарные исходы (зачет/незач, неявка)

Что входит в признаки

Профиль студента: пол, возраст, гражданство, общежитие, условие зачисления

Учебный контекст: направление, семестр, учебный год, дисциплина, вид контроля, попытка

Агрегаты успеваемости: средние/кол-во предметов/несдачи (в витринах признаков)

Таблица 1. Оценка 2–5

Расширенная история

Строк: 112 146, признаков: 54

Много признаков по семестрам → структурные пропуски у младших курсов

Баланс: 2: 7.4% • 3: 38.5% • 4: 31.5% • 5: 22.6%

Таблица 2. Бинарный исход

Расширенная история

Строк: 89 443, признаков: 40

Сдал/не сдал (0/1) → сильный дисбаланс классов
Баланс: 1: 94.5% • 0: 5.5%

Таблица 3. Оценка 2–5

Компактные лаги

Строк: 87 550, признаков: 20

Лаговые агрегаты до текущего/предыдущего семестра → меньше шума

Баланс: 2: 6.4% • 3: 37.7% • 4: 31.1% • 5: 24.7%

Таблица 4. Бинарный исход

Компактные лаги

Строк: 65 494, признаков: 19

Оптимальна для inference → без семестрового раздувания признаков

Баланс: 1: 95.5% • 0: 4.5%



Выбор модели

сравнение 8 моделей из 4-х классов

Метрики ансамблевой модели LightGBM для бинарных значений с пропусками NaN

Метрика	Целевое значение	Фактическое значение с NaN	Статус
Recall (полнота)	$\geq 0,95$	0,9932	
Precision (точность)	$\geq 0,90$	0,9746	
F1-Score	$\geq 0,90$	0,9838	



Выбор модели

сравнение 8 моделей из 4-х классов

Метрики ансамблевой модели LightGBM для качественных значений с NaN

Метрика	Целевое значение	Фактическое значение с NaN	Статус
Recall (полнота)	$\geq 0,75$	0,7342	
Precision (точность)	$\geq 0,70$	0,7331	
F1-Score	$\geq 0,70$	0,7322	

Разработка MVP: интерфейс и функциональность

1

Загрузка подготовленных данных

2

Управление режимами модели: обучение, переобучение, предсказание

3

Интерпретация результатов предсказания модели по методу SHAP

4

Расчет аналитических показателей успеваемости

5

Визуализация показателей успеваемости предиктивной аналитики

ІТМО

Глобальная аналитика




Глобальный анализ учебных потоков

Анализ построен на базе 22430 записей.

Структура студентов в зоне низкой успеваемости

Распределение студентов с GPA < 3.5 или имеющих исторические задолженности по условиям зачисления.



Все формы зачисления:

- По общему конкурсу
- Безступенчатых испытаний
- Общий конкурс
- По общему конкурсу
- По государственной квоте
- Безступенчатых испытаний
- Конкурс
- Внеквотный
- По государственной квоте
- Незачислено
- По общей квоте
- По целевой квоте
- По целевой квоте
- По целевой квоте
- На государственные места в пределах целевой квоты
- Квоты
- Спец. линия - нагрятия
- Спец. линия
- Целевой квоты
- На государственные места в пределах целевой квоты

Рейтинг сложности дисциплин


Поиск «предметов-барьеров». Чем дальше и выше находится предмет, тем больше студентов не могут его сдать.

Экран навигации «Прогнозирование и интерпретация»

ІІТМО

4. Прогноз и интерпретация


Прогноз системы по предмету «[30141] Производственная, технологическая (проектно-технологическая)»: Оценка: 5.0



5. Сравнение с потоком



6. Профиль компетенций



Сценарии использования продукта

1

Доля студентов с академической задолженностью
(фиксация и анализ зон низкой успеваемости)



2

Коэффициент сохранности контингента
(контроль оттока)

3


Доля платных студентов в зоне отставания
(финансовые риски)

4

Индивидуальный профиль успеваемости по факторам влияния
(превентивные меры)


Анализ критических порогов академ. задолженности

Влияние количества несданных предметов на прогноз итоговой оценки




Карта значимости факторов влияния на успеваемость

Степень влияния каждого фактора на итоговый прогноз модели



Индекс нагрузки. Кто генерирует больше пересдач?


7. Индекс нагрузки: Кто генерирует больше пересдач?



Индивидуальный профиль риска успеваемости студента

Вклад каждого фактора на отклонение прогноза от среднего

Декомпозиция прогноза для студента №943534 (группа риска)



Развитие MVP продукта



ETL - модуль

РАЗРАБОТКА

ETL - модуля для автоматизации процесса подготовки сырых данных



Новые функции

ДОБАВЛЕНИЕ

функций работы с моделью



Функциональность

РАСШИРЕНИЕ

категорий входных данных, функциональности по сборке графиков и дашбордов



Web-версия

РАЗРАБОТКА

web-версии программы

1

Разработали улучшенную методику обучения модели с использованием эталонных данных



2

Реализовали интерпретацию результатов предсказания модели с использованием метода SHAP

3

На основе обученной модели разработали MVP программного продукта

4

На основе MVP создали возможность разработки интеллектуального инструмента поддержки и сопровождения учебного процесса

**Спасибо
за внимание!**

ITMO *re than a*
UNIVERSITY

Сергей Покровский pokrovskiy@itmo.ru

1. LightGBM Developers. LightGBM: Python API [Электронный ресурс]. —   Режим доступа: <https://lightgbm.readthedocs.io/en/latest/pythonapi/lightgbm.LGBMClassifier.html> (дата обращения: 15.03.2026).
2. Lundberg S. M. SHAP (SHapley Additive exPlanations) [Электронный ресурс]. — Режим доступа: <https://shap.readthedocs.io/en/latest/> (дата обращения: 20.03.2026).
3. Guan Y., Wang F., Song S. Interpretable machine learning for academic performance prediction: A SHAP-based analysis of key influencing factors //Innovations in Education and Teaching International. — 2025. — С. 1-20.